

# S9 资料全量审读与外部链接归档报告

覆盖 S9 五题、历届赛题工作簿、往届开源仓库、赛事与云资源材料

|      |               |        |               |
|------|---------------|--------|---------------|
| 审计日期 | 2026-07-25    | 唯一外部链接 | 167           |
| 仓库拉取 | 43 成功 / 70 失败 | 网页归档   | 97 成功 / 70 失败 |

## 1. 结论先行

是的，Concat 的差结果与此前没有完整按题目规格设计直接相关。当前实现只覆盖 FP16、二维/末维快路径，而题目要求任意 rank、任意合法 dim、多 dtype、动态输入、空分片和 non-contiguous。Case1 只证明样例快路径可运行，不能证明实现满足赛题。

- 9 个赛题工作簿全部重新读取，提取 40 个技术文档链接；S9 的 6 个 PyTorch 2.5 页面和 index\_add\_ 跟进页均已保存。
- Word 的 HYPERLINK 字段和 PDF 注释链接也已纳入，总计 167 个唯一链接。
- 113 个仓库逐一尝试完整 clone：43 个成功，70 个失败；成功项保留 .git、分支和 HEAD。
- 43 个成功仓库已建立代码审读矩阵：1396 个索引文件、401 个 C/C++ 源文件。
- 敏感文件 GCC.pem 未复制到资料包。

## 2. S9 五题完整规格与当前缺口

| 算子          | 完整规格                                                                                                             | 当前实现                                                                                      | 风险                                                                    | 下一步                                                                      |
|-------------|------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|-----------------------------------------------------------------------|--------------------------------------------------------------------------|
| Concat      | Tensor[]; dim 默认 0; float32/float16/int32/int8; 任意 rank 和合法 dim; 除拼接轴外形一致; 允许 1D 空张量和长度 0 分片; 非对齐。               | 仅 FP16, kernel 把最后一维当拼接轴; host 虽按 dim 推输出 shape, 但 tiling/kernel 不使用 dim; 地址数组只容纳 16 个输入。 | 直接解释 Case1 通过、Case2-5 Run failed。隐藏用例只要改变 dtype、rank、dim、输入数或尾块就可能失败。 | 通用 N-D fallback + last-axis 快路径; 动态输入数; 0 长度输入; 尾块 DataCopyPad; 多 dtype。 |
| Greater     | self/other; float32/bfloat16/float16/int32/int8; 输出 bool; 支持广播; 覆盖 inf、-inf、NaN。                                 | 仅 FP16 等形; 输出 shape 直接等于 self; 整张量进 UB; 以 SubRelu/Mins/Cast 代替 Compare。                   | 广播不成立, 较大张量 UB 超限; NaN/Inf、溢出和非对齐都可能产生错误或运行失败。                        | 广播步长映射; 原生比较语义; 分块; 多 dtype; 特殊值回归。                                      |
| IndexAdd    | self/index/source; dim 默认 0; index 为 int32 一维向量; source[dim]=len(index), 其他维匹配 self; 重复 index 必须累加; 输出从 self 开始。 | 忽略 self; 仅 int8、二维、dim=0; 空 index 有 blockDim=0 风险; source/out 非对齐复制未覆盖。                   | 当前实现不满足基础定义; 重复索引、任意维度和其他 dtype 均不可靠。                                 | 先复制 self; 重复 index 正确累加; 任意 rank/dim; 冲突策略; 多 dtype 和尾块。                 |
| Transpose   | input + dims 列表; float32/float16/int32/int8; 最高 6D 任意排列; 非对齐。                                                    | 仅 FP16 二维交换; 忽略 dims; 仅处理 16×16 整块; 任一维小于 16 时 totalTiles=0。                              | 任意排列、尾块、非二维都不支持, 且小尺寸存在除零/零核风险。                                       | 通用坐标映射; 尾块; 2D 16×16 快路径; 任意 dims/rank/dtype。                            |
| SquareSumV1 | square 后 sum; axis 为 list_int; keep_dims 默认 false; float16/bfloat16/float32; 单轴/多轴/负轴; 非对齐。                      | 仅 FP16 最后一轴; 输出 shape 强制保留最后一维; 忽略 axis/keep_dims; FP16 先平方再转 FP32。                       | 多轴、非末轴、keep_dims=false、BF16/FP32 均不完整; FP16 平方会先溢出或损失精度。              | 轴归一化; FP32 中间计算; 多轴分阶段或通用回退; 正确输出 shape。                                 |

### 3. Concat 线上结果复盘

线上结果：Case1 Pass, 10.948  $\mu$ s; Case2–Case5 Run failed。

- host InferShape 使用 dim, 但 tiling/kernel 固定按最后一维解释, dim 非末维时语义冲突。
- OpDef 只声明 DT\_FLOAT16, 题目还要求 float32、int32、int8。
- ListTensor 地址数组只有 16 项, 动态输入列表可能超过固定容量。
- 实现把除最后一维外全部折叠成 outer, 只适用于末维拼接。
- 没有通用回退路径, 输入不匹配快路径时直接运行失败。

下一轮必须先建立全规格通用路径, 再为常见 dtype、末维、对齐形状增加快路径, 不能继续只围绕 Case1 微调。

### 4. 往届优秀代码的可复用经验

- 非对齐是常态: 43 个成功仓库中 25 个使用 DataCopyPad。
- 35 个仓库使用 C++ template, 多 dtype 不应靠复制多份实现。
- TILING\_KEY/模板特化用于拆分对齐快路径和通用 fallback。
- UB 按预算切 tile, 不把整张量一次性放进 UB。
- IndexAdd 应参考 ScatterReduce/Gather/Expand 的多维坐标、stride、重复 index 和冲突处理。
- SquareSumV1 应先转换 FP32, 再平方与累加, 最后按输出 dtype 转换。
- 双缓冲必须与真实 tile 循环重叠, 否则 BUFFER\_NUM 增大没有实际收益。

| 本地仓库目录                                      | 主要学习价值                                                             |
|---------------------------------------------|--------------------------------------------------------------------|
| R002_gitcode_szdaniel_S6T                   | S6 多算子完整工程; Fmin/Hypot/Logcumsumexp; 大量 DataCopyPad、模板化 dtype 和分块。 |
| R078_github_Brown-Bert_S5                   | GatherV3 与 ReduceLogSumExp; 索引映射、规约和可提交工程结构。                       |
| R079_github_bubu-12_Ascendc-S4              | ScatterReduce; 多维坐标拆解、scatter 轴步长和非对齐搬运, 可映射到 IndexAdd。            |
| R097_github_Qeeweew_AscendC-S6-Logcumsumexp | 分行规约、事件同步、流水和边界处理。                                                 |
| R104_github_ustc1587_ReduceLogSumExp        | FP16→FP32 转换、双缓冲和 ReduceSum 组织, 可映射到 SquareSumV1。                  |
| R107_github_winfan1314_AscendC-S4-Base      | Gather/Pows/Reshape; TILING_KEY 快慢路径与 scalar fallback。             |
| R108_github_wybxw_Ascend_ops_Base_S6        | Expand; 任意 dtype 模板、广播坐标映射、UB 预算和尾块写回。                             |
| R109_github_wybxw_Ascend_ops_Performance_S6 | Hypot; float/half/bfloat16 模板、计算 dtype 分离和分块。                      |

### 5. 推荐优化顺序与验收门槛

1. 冻结 dtype × rank × axis/dim × 对齐 × 空输入 × 特殊值 × 重复 index 的语义矩阵。
2. 五题先建立通用正确路径, 所有本地扩展测试与远端功能用例通过。
3. 只在条件满足时进入快路径; 否则必须回退, 不能 Run failed。
4. 再做 tiling、核数、双缓冲、vector 指令和 GM 往返优化。
5. 每次提交记录代码提交号、zip 哈希、Case 结果和日志, 避免本地/远端/仓库不同步。

## 6. 外部链接与仓库归档结果

| 类别     | 总数  | 成功       | 失败 | 说明                |
|--------|-----|----------|----|-------------------|
| 唯一外部链接 | 167 | 97 网页    | 70 | 逐项状态见审计工作簿        |
| 仓库链接   | 113 | 43 clone | 70 | 保留 .git/分支/HEAD   |
| 赛题工作簿  | 9   | 9 已读     | 0  | 40 个唯一技术链接        |
| S9 技术页 | 6+1 | 7        | 0  | index_add_ 为必要跟进页 |

## 7. 无法获取与限制

- Gitee：大多数 clone 返回平台 reject/HTTP 400，网页返回 HTTP 405；属于平台或当前网络环境拒绝。
- GitCode：Lijianhao2/AscendS6 要求登录；szdaniel/S6T 已成功 clone。
- GitHub：wilburx813/ascend\_s4 返回 Repository not found，网页 404。
- pytorch.ac.cn 的 2 个历史链接当前无法保存；原链接与错误已记录，其余 38 个工作簿技术页成功。
- http://e.huawei.com 返回 502；手册中的 ModelArts 页面和控制台链接已保存。
- 本机没有 Word/LibreOffice/WPS 渲染器，DOCX 无法视觉复核；本 PDF 已逐页检查。

## 8. 资料包结构

| 目录            | 内容                      |
|---------------|-------------------------|
| 00_材料索引       | 文件、链接、网页、仓库与目录映射。       |
| 01_S9赛题原文与规格  | 原始材料、官方 zip_op.sh、五题规格。 |
| 02_网页归档       | 97 个成功响应。               |
| 03_往届冠军仓库快照   | 43 个完整仓库。               |
| 04_往届赛题与代码分析  | 历届原始包、解压内容、工作簿与代码矩阵。    |
| 05_无法获取与待人工处理 | 失败原因与可重试条件。             |
| 06_报告与验收清单    | 主报告、审计工作簿和预览。           |

## 9. 下一轮优化前需要的条件

- 以 ModelArts /home/ma-user/work/ 的实时代码为准，先同步回本地并记录远端 commit/文件哈希。
- 保持 CANN 社区版 8.5.0、Ascend 910B 和 Euler 2.10。
- 远端命令写入 /home/ma-user/work/s9/codex-visible-terminal.log，便于在 JupyterLab 实时查看。
- 先跑完整功能矩阵和日志，再提交榜单；不再用单一样例通过代替题目通过。